

一、Attention 架构与参数总览

Model	Attention Mechanism	Heads / KV Representation	Head Dim	Layer Pattern
Kimi K3	Kimi Delta Attention + Gated MLA full attention	KDA: 96 heads; MLA: 96 Q heads, KV latent rank=512, Q latent rank=1536	KDA: 128; MLA: QK=128 + 64 但是都是 NOPE 应该是为了 infra 保持了 MLA 的设计, V=128	93 层: 69 KDA + 24 Gated MLA; 大体为 3 KDA : 1 MLA, 最后一层额外使用 Gated MLA。
Qwen3.8-2.4T-A95B	Gated DeltaNet linear attention + Gated Full Attention	DeltaNet: 16 QK heads / 128 V heads; Full: 64 Q / 4 KV	DeltaNet: 128; Full: 256, 其中 RoPE 维度 64	92 层: 23 × (3 DeltaNet + 1 Full)。
DeepSeek-V4-Pro	CSA + HCA; Shared K=V MQA。CSA: 4× overlapping learned KV compression + Lightning Indexer top-1024; HCA: 128× non-overlap compression + dense attention; 均附带 local SWA	128 Q heads; 1 shared K=V representation; Q latent rank=1536; Indexer=64 heads, top-k=1024; grouped output: 16 groups / rank=1024	512 = 448 NoPE + 64 RoPE; Indexer=128	61 层: 前 2 HCA, 之后 CSA/HCA 交替, 共 31 HCA + 30 CSA; 所有层额外使用 window=128 local branch; 另有 1 MTP layer, 仅 SWA
GLM-5.3	继承 GLM-5.2 base 的 DSA on MLA, 并使用 IndexShare	64 Q heads; KV latent rank=512; Q latent rank=2048; Indexer: 32 heads; Sparse top-k=2048	QK=192 NoPE + 64 RoPE; V=256; Indexer=128	78 层: 均为 DSA/MLA; 前三层各自运行 Indexer, 之后基本为 1 Full Indexer + 3 Shared, 后 3 层复用同一 top-k indices。
MAI-Thinking-1	GQA; Sliding Window + Full Attention	80 Q / 8 KV	128	78 层: 5 Local + 1 Global, 即 65 Local + 13 Global; Local window=512。Local 使用 RoPE, Global 完全 NoPE。
TML Inkling	GQA; Sliding Window + Full Attention	Global: 64 Q / 8 KV; Local: 64 Q / 16 KV	128; Relative-position dim=16 (position 的故事我们之后再聊), QK logits scale 使用 1/d (好神奇)	66 层 = 11 × (5 Local + 1 Global), 55 Local + 11 Global; window=512; 每层 K/V projection 后及 Attention/MLP residual branch 输出处使用 kernel=4 Conv
MiMo-V2.5-Pro	GQA; Sliding Window + Full Attention	128 Q / 8 KV	QK=192; V=128, Q/K 使用 Partial RoPE: 64-d RoPE + 128-d NoPE, V 固定乘 0.612 (应该来自 $\approx \sqrt{\frac{6144}{128 \times 128}}$)	70 层: 60 SWA + 10 Full, 即 6 Local : 1 Full; window=128; SWA 额外加入 per-head attention-sink bias, 使注意力可以将无用概率质量分配给这个 bias 并丢掉。
MiniMax-M3	MSA: GQA 上的 blockwise sparse attention; 每个 GQA group 独立进行 block retrieval	64 Q / 4 KV; Indexer: 4 Q heads, 共享 Index K	Attention=128 = 64 RoPE + 64 NoPE; Indexer=128	60 层: 前 3 层 Full GQA, 后 57 层 MSA。每个 query group 选择 top-16 个、每个 128-token 的 block, 即约 2048 tokens, 并强制包含 local block。
LongCat-2.0	LSA on MLA: 先、固定选 (16 sink + 1024 local window); 先按 block 粗筛然后在候选 block 内选 token; 相邻 2 层共享一次 Index	64 Q heads; KV latent rank=512; Q latent rank=1536; Indexer: 32 heads; top-k=2048	QK=128 NoPE + 64 RoPE; V=128; Indexer=128	38 层; 相邻两层共享索引。
Hy3	GQA	64 Q / 8 KV	128	80 层 GQA
DeepSeek-V3	MLA	128 Q heads; KV latent rank=512; Q latent rank=1536	QK=128 NoPE + 64 RoPE; V=128	61 MLA
Gemma 4	GQA; Local/Global Hybrid; 所有 Global 层使用 p-RoPE; 12B/26B/31B 的 Global 层使用 K=V; E2B/E4B 使用 cross-layer KV sharing	E2B: 8Q/1KV; E4B: 8Q/2KV; 12B: 16Q, Local 8KV / Global 1KV; 26B-A4B: 16Q, Local 8 / Global 2; 31B: 32Q, Local 16 / Global 4	Local=256, 全维 RoPE; Global=512, 其中 128 RoPE + 384 NoPE	E2B: 35 层, 4L:1G, window=512; E4B: 42 层, 5:1, window=512; 12B: 48 层、26B: 30 层、31B: 60 层, 均 5:1、window=1024; 所有型号最后一层为 Global

二、Attention 机制概讲





Figure 3 | Simplified illustration of Multi-Head Attention (MHA), Grouped-Query Attention (GQA), Multi-Query Attention (MQA), and Multi-head Latent Attention (MLA). Through jointly compressing the keys and values into a latent vector, MLA significantly reduces the KV cache during inference.

MLA

Multi-Head Latent Attention (MLA)



MHA GQA MQA 都很一目了然我们边不过多介绍，下面我们来具体聊一下 MLA 一段话来说呢，就是：

MLA (Multi-Head Latent Attention) 的核心是用一个低维 latent 压缩所有 head 的 KV，同时保留多头不同的表达能力：输入 h_t 先下投影得到共享的低维 c_t^{KV} (DeepSeek-V3 中为 512-d)，再通过不同的上投影展开成各个 head 的 $k_{t,i}^C, v_{t,i}^C$ ；Q 侧类似先得到 c_t^Q ，再展开成各 head 的 $q_{t,i}^C$ 。由于 RoPE 会破坏这种低秩矩阵的 matrix absorption，MLA 把位置编码单独放到一个

较小的 RoPE 子空间 $q_{t,i}^R, k_t^R$ (如 64-d)，最终 $Q_i = [q_i^C; q_i^R]$ 、 $K_i = [k_i^C; k_i^R]$ 。训练时可以看到把 latent 展开成每个 head 不同的 K/V，获得接近 MHA 的表达能力；Decode 时利用 **matrix absorption** 不必保存/展开历史的完整多头 KV，只缓存 $c_t^{KV} + k_t^R$ ，因此 KV Cache 从 $O(Hd)$ 降到 $O(d_{\text{latent}} + d_R)$ ，大幅降低显存和解码带宽。

用苏神的话来说呢，就是：

1. MLA 在训练阶段是一个 $\text{qk_head_dims}=(128+64)$ 、 $\text{v_head_dims}=128$ 的 MHA；
2. MLA 在解码阶段是一个 $\text{qk_head_dims}=(512+64)$ 、 $\text{v_head_dims}=512$ 、KV-Shared 的 MQA。

DSA




Figure 2 | Attention architecture of DeepSeek-V3.2, where DSA is instantiated under MLA. The green part illustrates how DSA selects the top-k key-value entries according to the indexer.

DSA (DeepSeek Sparse Attention) 可以理解为在真正的 MLA Attention 前加一个轻量的 Lightning Indexer 做 token 路由：对当前 token 的 hidden state x_t 生成 64 个 128-d Indexer Query Q_I ，每个历史 token x_s 生成一个共享的 128-d Indexer Key K_I ；64 个 Query 分别与全部历史 Key 做点积，经 ReLU 后，再用当前 token 生成的 64 个 head weight 加权汇总，得到每个历史 token 唯一的 relevance score $I_t[s]$ ，然后 Top-K 选出最相关的 2048 个历史 token。Indexer 本身只负责“哪些 token 值得看”，真正的 attention 仍由 MLA 完成，但 MLA 不再对全部长度 L 的 KV 做 attention，而只对选中的 2048 个 KV 做精确 attention，因此把核心 Attention 的复杂度从随上下文长度 L 增长，压到近似固定的 Top-K；

我承认我最开始是对于 DSA 有着一些误解的，我认为 DSA 会导致 Infra 非常难堪，但是今天下午经一位 Infra 群的大佬指教后我才恍然大悟，DSA 搭配 MLA 真的是非常奇妙：

DSA 的 per-query、fine-grained token Top-K 使传统沿 Q-token $\times$ K-token 的规则 attention tiling 难以直接使用：相邻 Q token 往往选择不同、离散的 K token 集合，因此无法让一块 Q tokens 共享同一块连续 K tile。MLA 则在 matrix-absorbed 的 MQA mode 下，让同一个 latent KV entry 被当前 token 的所有 query heads 共享，于是 kernel 可以改为沿 query-head $\times$ selected-K 组织计算，用多个 query heads 提供 Tensor Core 所需的规则矩阵维度，同时复用一次加载的 KV。

不得不再对 DeepSeek 团队的巧思五体投地的佩服。

DSA 的训练上，一般是从一个比较成熟的权重开始训练（DS3.2 是从 3.1 上训，GLM 是从 Mid-Train 开始训），然后分为两个阶段：

简单来讲：

1. **Dense 预热阶段**：保持主模型的 Dense Attention 不变，只训练 Indexer；用主 Attention 在全序列上的注意力分布作为 teacher，通过 KL loss 让 Indexer 学会在全局范围内准确判断哪些历史 token 更重要。
2. **Sparse 训练阶段**：启用 Top-K 稀疏选择并继续训练整个模型；Indexer 仍然对齐主 Attention，但只在已经选中的 **token 集合内部** 计算 KL，使 Indexer 学会把这些候选 token 的相对重要性和排序估得更准，同时主模型逐渐适应 Sparse Attention 的计算模式。

HCA/CSA

最复杂的一集来啦.....




Figure 3 | Core architectures of CSA. It compresses the number of KV entries to $\frac{1}{m}$ times, and then applies DeepSeek Sparse Attention for further acceleration. Additionally, a small set of sliding window KV entries is combined with the selected compressed KV entries to enhance local fine-grained dependencies.

CSA (Compressed Sparse Attention) 可以概括为：先用 **learned compressor** 对远距离 token 做 4:1 的可学习压缩，再用 **Lightning Indexer** 从压缩后的 KV 中做 Top-K 稀疏检索，最后与最近 128 个未压缩的 **local raw KV** 一起做 **core attention**。

其中 learned compressor 对每个 token 分别投影出 content 和逐-channel gate，对每个 channel 在一组 token 上做 softmax，再逐 channel 加权汇聚，得到一个 compressed KV；CSA 使用 **overlapping compression**：每个 compressed KV 覆盖连续 8 个原始 token，但压缩窗口每次只向前移动 4 个 token，因此相邻两个 compressed KV 会共享中间 4 个 token。在此之上 Lightning Indexer 会对这些 compressed KV 打分并只选择 Top-K（V4-Pro 为 1024）进入真正的 attention；同时最近 128 个 token 保留原始 KV，以保留局部细粒度信息。最终 core attention 使用 Shared-KV MQA，多组 Q head 共享同一套 KV，并采用 $K = V$ 。





Figure 4 | Core architectures of HCA. It performs heavier compression, where the KV entries of m' ($\gg m$) tokens will be consolidated into one. Also, we additionally introduce a small set of sliding window KV entries to enhance local fine-grained dependencies.

HCA (Heavily Compressed Attention): 用 learned compressor 将远距离 token 做 128:1 的 non-overlapping 压缩, 然后直接对全部 compressed KV 做 dense attention, 不再使用 Lightning Indexer 或 Top-K; 同时保留最近 128 个 raw KV 参与 dense attention。


Gated DeltaNet



Gated DeltaNet 用固定大小的 recurrent state S_t 压缩历史信息：输入投影得到 q, k, v, α, β ，之后， q, k, v 先经过短卷积， q, k 再做 L2 Norm； α 由 Linear 后经过一系列操作（我把代码贴下面了）映射到 $(0, 1]$ ，是 **per-head scalar retention gate**，控制旧状态保留多少； $\beta = \sigma(W_\beta x_t)$ 也是 **per-head scalar**，控制当前 Delta update 的强度。Delta Rule 根据当前 key 下的预测误差 $v_t - S^\top k_t$ 修正状态；随后用 q_t 从状态读出结果，经过 Zero-Centered RMSNorm、output gate（出自 Gated Attention，伟大无需多言）和 Linear 得到输出。核心就是： α 控制遗忘， β 控制写入，**Delta Rule** 用预测误差更新记忆。

```
# Qwen / Gated DeltaNet
a = a_proj(x)                # [B,T,H] 当前 token 为每个 head 生成 decay logit
z = a + dt_bias              # [B,T,H] 加每个 head 的可学习 decay bias
A = exp(A_log)              # [H] 每个 head 的基础遗忘速度
g = -A * softplus(z)        # [B,T,H] log-decay, 保证 g < 0
alpha = exp(g)              # [B,T,H] 真正保留率, 0 < alpha <= 1
S = alpha * S               # 每个 head 的整个 state 使用同一个 alpha 衰减
```

Kimi Linear



Kimi Delta Attention (KDA) 整体框架和 Gated DeltaNet 很接近：同样用固定大小的 recurrent state S_t 压缩历史信息，输入 x_t 投影得到 q, k, v, α, β ，Q/K/V 经过 short conv， q, k 再做 L2 Norm； $\beta = \sigma(W_\beta x_t)$ 仍然是 **per-head scalar**，控制当前 Delta update 的强度。**KDA** 最核心的改动在 α （代码同样附下）：Gated DeltaNet 每个 head、每个 token 只有一个 scalar α_t ，整个 state 一起衰减；KDA 则由 x_t 通过额外的 fine-grained gating projection 生成一个 **per-channel** 向量 α_t ，用 $\text{Diag}(\alpha_t)$ 对 state 的不同 key/memory channel 分别控制遗忘。状态更新仍采用 Delta Rule，根据 $v_t - S^\top k_t$ 的预测误差，以 β 控制强度修正 state，之后用 q_t 读取 state，再经 RMSNorm、output gate 和 Linear 得到输出。

```
# Kimi K3 / KDA
z = f_proj(x) + dt_bias      # [B,T,H,K] 每个 head 的每个 key channel 都生成 decay logit
A = exp(A_log)              # [H] 每个 head 的整体 decay scale
g = -5 * sigmoid(A[...None] * z) # [B,T,H,K] bounded log-decay, -5 < g < 0
alpha = exp(g)              # [B,T,H,K] 每个 key channel 一个独立保留率
S = alpha[... :, None] * S  # 等价于 Diag(alpha) @ S, 不同 memory channel 分别遗忘
```