

1 MoE

R = 路由专家, S = 始终激活的共享专家, Dense $\times$ d = 前 d 层使用普通 Dense FFN。

1.1 三种主要负载均衡方法

令 N 为专家数, K 为 Top- K , T 为 Token 数。定义专家 i 的实际负载比例 f_i 和路由概率比例 P_i :

$$f_i = \frac{1}{KT} \sum_{t=1}^T \mathbf{1}[i \in \mathcal{S}_t], \quad P_i = \frac{1}{T} \sum_{t=1}^T p_{t,i}.$$

1.1.1 A. 传统 GShard/Switch 辅助损失

$$\mathcal{L}_{\text{bal}} = \alpha N \sum_{i=1}^N f_i P_i$$

它会通过梯度直接改变 Router。

1.1.2 B. DeepSeek 式 Auxiliary-Loss-Free

$$\mathcal{S}_t = \text{TopK}_i(s_{t,i} + b_i).$$

$$w_{t,i} = c \frac{s_{t,i}}{\sum_{j \in \mathcal{S}_t} s_{t,j}}, \quad i \in \mathcal{S}_t.$$

其中 b_i 只影响选谁, 不影响最终混合权重, 根据负载统计更新:

其中 f_i 是专家 i 的实际负载比例; 目标负载设为专家上的均匀分布: $\bar{\mathbf{f}} = (1/N, \dots, 1/N)$, 即 $\bar{f}_i = 1/N$ 。因此, 负载偏低的专家会得到正向 bias 修正, 负载偏高的专家会得到负向修正。

$$b_i \leftarrow b_i + \gamma \text{sign}(\bar{f}_i - f_i)$$

1.1.3 C. Kimi K3 Quantile Balancing

不使用额外的负载均衡 loss，而是根据当前训练步的 Router score margin 分布直接估计下一步的专家偏置。

对每个 Token i ，先在当前带偏置分数 $s_{i,j} + b_j^{(t)}$ 上取 Top- $(K + 1)$ ，将第 $(K + 1)$ 大值记为带偏置 cutoff：

$$\alpha_i^{(t)} = \text{Top}_{K+1,j} \left(s_{i,j} + b_j^{(t)} \right).$$

随后对每个专家 j 计算原始 Router score 相对该 cutoff 的 margin：

$$m_{i,j}^{(t)} = s_{i,j} - \alpha_i^{(t)}.$$

并令下一步的未中心化专家偏置为：

$$\hat{b}_j^{(t+1)} = -\text{Quantile}_{1-K/N} \left(m_{:,j}^{(t)} \right)$$

最后 K3 还对所有专家 bias 做均值中心化（这一步其实不影响排序，问了下苏神是因为这么做好看哈哈哈哈）：

$$b^{(t+1)} = \hat{b}^{(t+1)} - \text{mean} \left(\hat{b}^{(t+1)} \right) \mathbf{1}$$

1.2 模型对比

模型	总参数 / 激活参数	MoE 配置	Router 与权重	负载均衡	Dense 部分	特殊设计
Kimi K3	2.78T / 104.2B	93 层; 16/896 R + 2 S	$s = \text{Sigmoid}(z)$; 按 $s + b$ 选 Top-16; Top-16 内 s 归一化; scale = 1.0	C 类	前 1 层	Stable LatentMoE: R 用完整输入做 Router, 同时将输入降维到 latent, 送入 Top-16 SiTU-GLU 专家加权聚合, 再 RMSNorm、升维, 并与 Shared Expert 输出相加。
DeepSeek-V4-Pro	1.6T / 49B	61 层; 6/384 R + 1 S	$s = \sqrt{\text{softplus}(z)}$; 按 $s + b$ 选 Top-6; Top-6 内 s 归一化; scale = 2.5	B 类; 加轻量 sequence-wise loss	没有, 前三层 Hash-MoE	前三层使用 Hash-MoE, 由输入 Token ID 的预定义哈希函数确定 expert; clamped SwiGLU。
GLM-5.2	744B / 40B	78 层; 8/256 R + 1 S	Sigmoid; 按 $s + b$ 选 Top-8; Top-8 内归一化; scale = 2.5	B 类	前 3 层	无额外设计
MAI-Thinking-1	962B / 34.7B	78 层; 8/512 R	Softmax gating; 取 Top-8; Top-8 后是否再次归一化未说明; scale 未说明	A 类	交替	LatentMoE: 用完整表示路由, 只传输压缩 latent。
TML Inkling	975B / 41B	66 层; 6/256 R + 2 S	Sigmoid; 仅 Routed Experts 加 bias 后选 Top-6; 6R 与 2S 分数联合归一化; 归一化后的联合加权结果再乘 scale = 8 $\times$ 每层可学习 scale	B 类	前 2 层	6 个 Routed Expert 和 2 个 Shared Expert 的 Sigmoid 分数联合归一化; 联合加权结果统一施加固定常数 8 和每层可学习 scale (这个值特别有意思, 有兴趣的可以 print 下)。
MiMo-V2.5-Pro	1.02T / 42B	70 层; 8/384 R	Sigmoid; 按 $s + b$ 选 Top-8; Top-8 内 s 归一化	B 类	前 1 层	无额外设计
MiniMax-M3	428B / 23B	60 层; 4/128 R + 1 S	Sigmoid; 按 $s + b$ 选 Top-4; Top-4 内原始 s 归一化; scale = 2.0	B 类	前 3 层	clamped SwiGLU。
Qwen3.5-397B-A17B	397B / 17B	60 层; 10/512 R + 1 S	全 512 Softmax; 按 p 取 Top-10; Top-10 内再次归一化; scale = 1.0; Shared Expert 另有 Sigmoid Gate	A 类	没有	共享专家单独打分。
LongCat-2.0	1.6T / 48B	38 层; 12/(768 R + 128 Z), 其中 Z 为 Zero-compute Identity Expert	全 896 Softmax; 按 $p + b$ 取 Top-12; 不做 Top-12 renorm; scale = 9	B 类; 加轻量 Aux loss, 并适配 Zero Expert	没有	128 个 Z Expert 是零计算 Identity Expert (MoE++ 伟大!)。
HY-3	295B / 21B	80 层; 8/192 R + 1 S	Sigmoid + expert bias; 按 $s + b$ 选 Top-8; Top-8 内归一化; scale = 2.826	B 类	前 1 层	无额外设计
DeepSeek-V3	671B / 37B	61 层; 8/256 R + 1 S	Sigmoid; 按 $s + b$ 选 Top-8; Top-8 内 s 归一化; scale = 2.5	B 类; 加轻量 sequence-wise loss	前 3 层	256 $R \rightarrow$ 8 个 group; 选 Top-4 group; 再在其中选 Top-8 expert; 每个 Token 最多访问 4 个节点。