从范数到优化器：SGD 与 Muon

1. 统一视角：在更新预算内降低损失

设当前参数矩阵为 $W \in \mathbb{R}^{m\times n}$，更新为同形矩阵 ΔW，目标是最小化 $\mathcal{L}(W+\Delta W)$。若不限制 ΔW，就等于一次求出最优参数矩阵，通常难以做到。因此，改为在当前参数附近逐步降低损失：每一步先给定更新预算 $\varepsilon > 0$，再在预算内选择更新：

$$\min_{\|\Delta W\|\le\varepsilon} \mathcal{L}(W+\Delta W). \tag{1}$$

这里的范数用于衡量更新幅度，暂不指定。当预算足够小时，在当前参数处对损失作一阶展开：

$$\mathcal{L}(W+\Delta W) \approx \mathcal{L}(W) + \langle G, \Delta W\rangle, \qquad G = \nabla_W \mathcal{L}(W). \tag{2}$$

其中 $\langle G, \Delta W\rangle = \mathrm{Tr}(G^\top \Delta W) = \sum_{i,j} G_{ij}(\Delta W)_{ij}$。去掉常数 $\mathcal{L}(W)$，式（1）近似为：

$$\min_{\|\Delta W\|\le\varepsilon} \langle G, \Delta W\rangle. \tag{3}$$

为分开表示更新的方向和幅度，将非零更新写成：

$$\Delta W = \underbrace{\frac{\Delta W}{\|\Delta W\|}}_{\text{方向}D} \times \underbrace{\|\Delta W\|}_{\text{幅度}\rho} = \rho D. \tag{4}$$

其中 $\|D\| = 1$，$\rho > 0$ 是表示更新幅度的实数标量，预算约束为 $\rho \le \varepsilon$。此时目标为 $\rho\langle G, D\rangle$。当 $G \neq 0$ 时，最优方向的内积为负，沿该方向用满预算可使线性目标下降最多。因此，只需先求最优单位方向，再乘以预算 [1, 2]：

$$D^* \in \arg\min_{\|D\|=1} \langle G, D\rangle, \qquad \boxed{\Delta W^* = \varepsilon D^*.} \tag{5}$$

以下推导考虑非零梯度；梯度为零时，局部问题可取零更新。

2. Frobenius 范数：从归一化更新到 SGD

Frobenius 范数 $\|D\|_{\mathrm{F}} = (\sum_{i,j} D_{ij}^2)^{1/2}$ 等于矩阵展平后的 ℓ_2 范数。选择 Frobenius 范数后，式（5）就是在 $\|D\|_{\mathrm{F}} = 1$ 的约束下最小化 $\langle G, D\rangle$。由矩阵内积的柯西-施瓦茨不等式：

$$|\langle G, D\rangle| \le \|G\|_{\mathrm{F}} \|D\|_{\mathrm{F}} = \|G\|_{\mathrm{F}}. \tag{6}$$

因此，内积的下界为 $-\|G\|_{\mathrm{F}}$，在 $D = -G/\|G\|_{\mathrm{F}}$ 时取到。乘以预算，得到：

$$D^* = -\frac{G}{\|G\|_{\mathrm{F}}}, \qquad \boxed{\Delta W^* = -\varepsilon \frac{G}{\|G\|_{\mathrm{F}}}.} \tag{7}$$

固定预算 ε 得到的是归一化梯度下降。普通 SGD 对应的预算为 $\varepsilon_t = \eta_t \|G_t\|_{\mathrm{F}}$，即学习率 η_t 乘以当前小批量梯度矩阵 G_t 的 Frobenius 范数。代入式（7）后，梯度范数相消，得到：

$$\varepsilon_t = \eta_t \|G_t\|_{\mathrm{F}} \quad \Longrightarrow \quad \boxed{W_{t+1} = W_t - \eta_t G_t.} \tag{8}$$

这一更新可逐元素计算：$(\Delta W_t)_{ij} = -\eta_t G_{t,ij}$。它也是近端梯度（proximal gradient）在无非光滑项时的随机版本 [3]。

3. 固定谱范数预算得到 Muon

矩阵的另一种常用范数是谱范数，用来衡量矩阵对向量长度（ℓ_2 范数）的最大放大倍数，其值等于矩阵的最大奇异值：

$$\|\Delta W\|_2 = \max_{\|x\|_2=1} \|\Delta W x\|_2 = \sigma_{\max}(\Delta W). \tag{9}$$

选择谱范数并令预算 $\varepsilon = \eta$ 后，式（3）就是在 $\|\Delta W\|_2 \le \eta$ 的约束下最小化 $\langle G, \Delta W\rangle$。为求出最优更新，先对梯度矩阵 G 作紧致 SVD，仅保留非零奇异值：

$$G = U_r \Sigma_r V_r^\top = \sum_{i=1}^{r} \sigma_i u_i v_i^\top, \qquad \sigma_i > 0. \tag{10}$$

由于 u_i, v_i 都是单位向量，$u_i^\top \Delta W v_i \ge -\|\Delta W\|_2 \ge -\eta$，所以：

$$\langle G, \Delta W\rangle = \mathrm{Tr}(G^\top \Delta W) = \sum_{i=1}^{r} \sigma_i u_i^\top \Delta W v_i \ge -\eta \sum_{i=1}^{r} \sigma_i. \tag{11}$$

取 $\Delta W = -\eta U_r V_r^\top$ 时，$\|\Delta W\|_2 = \eta$ 且每个 $u_i^\top \Delta W v_i = -\eta$，恰好达到下界。因此，固定谱范数预算的一个最优更新为：

$$\boxed{\Delta W^* = -\eta U_r V_r^\top.} \tag{12}$$

这直接给出 Muon 的核心更新 [4]。原奇异值 σ_i 决定一阶损失最多能下降多少，即 $\eta \sum_i \sigma_i$；各非零奇异方向上的更新幅度则都为预算 η。相比之下，普通 SGD 在这些方向上的幅度为 $\eta\sigma_i$。实际 Muon 对动量矩阵进行近似正交化，并可配合维度缩放 [5]。

4. RMS→RMS 算子范数得到 μP 版 Muon

在线性层 $y = Wx$ 中，n 为输入维度，m 为输出维度。为比较不同宽度下激活分量的典型大小，使用均方根（RMS）：

$$\|v\|_{\mathrm{RMS}} = \sqrt{\frac{1}{d}\sum_{i=1}^{d} v_i^2} = \frac{\|v\|_2}{\sqrt{d}}, \qquad v \in \mathbb{R}^d. \tag{13}$$

输入和输出都用 RMS 衡量，便得到 RMS→RMS 算子范数 [4]：

$$\begin{aligned} \|\Delta W\|_{\mathrm{RMS}\to\mathrm{RMS}} &:= \max_{x\neq 0} \frac{\|\Delta W x\|_{\mathrm{RMS}}}{\|x\|_{\mathrm{RMS}}} \\ &= \max_{x\neq 0} \frac{\|\Delta W x\|_2/\sqrt{m}}{\|x\|_2/\sqrt{n}} = \sqrt{\frac{n}{m}}\,\|\Delta W\|_2. \end{aligned} \tag{14}$$

固定预算 $\|\Delta W\|_{\mathrm{RMS}\to\mathrm{RMS}} \le \eta$，等价于 $\|\Delta W\|_2 \le \eta\sqrt{m/n}$。因此，将式（12）的谱范数预算替换为 $\eta\sqrt{m/n}$，就得到 μP 版 Muon 更新 [4]：

$$\boxed{\Delta W_{\mu\mathrm{P}} = -\eta\sqrt{\frac{m}{n}}\, U_r V_r^\top.} \tag{15}$$

关于 μP 的具体内容，非常非常推荐参考这三篇文章哇 [6, 12, 13]（苏神和 Greg Yang 还是太权威了）.

5. 从 Muon 到 Moonlight

沿用前文记号，ΔW_t 表示梯度驱动的参数增量，**包含学习率及下降方向的负号**；权重衰减单独写出：

$$\boxed{W_{t+1} = (1 - \eta_t \lambda_{\text{wd}}) W_t + \Delta W_t.} \tag{17}$$

其中 λ_{wd} 是权重衰减系数，后文简称 WD。记 H_t 为送入正交化的动量矩阵，普通动量与一种常见的 Nesterov 写法分别为：

$$M_t = \mu M_{t-1} + G_t, \qquad H_t = \begin{cases} M_t, & \text{普通动量,} \\ G_t + \mu M_t, & \text{Nesterov.} \end{cases} \tag{18}$$

$$\Delta W_t = -\eta_t \begin{cases} \text{NS}_5(H_t), & \text{原始 Muon 基线,} \\ 0.2\sqrt{\max(m,n)}\ \text{NS}_5(H_t), & \text{Moonlight.} \end{cases} \tag{19}$$

这里 NS_5 表示 5 步 Newton-Schulz 近似正交化，我们在之后再具体介绍。

Moonlight + Kimi K2 引入的 QK-Clip，可概括为三点：

1. **加入 weight decay**。按式（17）施加解耦权重衰减，抑制权重及激活幅度持续增长。
2. **更新 RMS 对齐 Adam**。乘以 $0.2\sqrt{\max(m,n)}$，使未乘学习率的更新 RMS 大致对齐 Adam 的典型量级 0.2（此事在 https://kexue.fm/ 记载），从而可直接复用 Adam 调好的**学习率和权重衰减率**，减少重新搜索超参数的成本 [7, 8]。
3. **QK-Clip**。在每步更新后，若某个注意力头的最大 attention logit 超过阈值，则按比例缩小 Q/K 权重，抑制 attention logit 爆炸 [9]。

这里的更新 RMS 与之前输入输出扰动比例的 RMS→RMS 算子范数不同，指 $\text{RMS}(\Delta W/\eta) = \|\Delta W\|_{\text{F}}/(\eta\sqrt{mn})$，衡量更新元素的整体大小。

6. 核心对比表

除特别标注外，下表描述预训练配置。更新量沿用式（19）的写法，权重衰减按式（17）计算。

表中沿用式（19）的写法，$W \in \mathbb{R}^{m\times n}$ 表示实际参与一次更新计算的矩阵。按头处理时，W 就是一个头对应的子矩阵，m, n 取该子矩阵的行列数；各头分别计算更新后，按原位置组合成整个权重矩阵的更新。

PE_8 表示 8 步 Polar Express，SK_{11} 表示含弱行屏蔽的 11 步 Sinkhorn 均衡；s 表示当前矩阵的更新缩放系数。Muown 中，g 是行幅度，$H_{R,t}$ 是方向变量的动量矩阵，$\widehat{m}_{g,t}, \widehat{v}_{g,t}$ 是幅度梯度的 Adam 矩估计。MiMo 公式按基础系数 0.2 合并 RL 额外缩放 0.5，写为 0.1。具体计算见第 7 节，K3 的 QK-Clip 见式（27）。

模型	核心更新	相比原始 Muon 的主要修改	参数分工与设置
Qwen3.8-Flash-Next	$\Delta W_t = -0.2\eta_t\sqrt{\max(m,n)}\ \mathrm{PE}_8(H_t)$。	**Moonlight 缩放 + 8 步 Polar Express + 更细拆分**。QKV、GDN 输入投影按头拆；SwiGLU FC1 拆 gate/up，缩放按子矩阵尺寸计算。	Nesterov，$\mu = 0.95$。Embedding、LM head、router、GR 低秩投影用 AdamW；N-gram 表用 Adam。
DeepSeek-V4.1-Flash	主干矩阵： $\Delta W_t = -\eta_t s\ \mathrm{NS}(H_t)$, Engram、embedding、LM head： $\Delta W_t = -0.18\eta_t\sqrt{n}\ \mathrm{SK}_{11}(H_t)$.	在 V4 基础上增加 **Head-wise Muon**；**Engram 表、token embedding、LM head 改用 Sinkhorn 行列均衡更新**。	Muon：目标 RMS 为 0.18，$\mu = 0.95$、WD=0.1。Sinkhorn：**无 WD**；Engram LR 额外 ×5。Norm/非矩阵参数用 AdamW。
DeepSeek-V4-Pro	$\Delta W_t = -0.18\eta_t\sqrt{\max(m,n)}$ $\cdot\ \mathrm{HybridNS}_{8+2}(H_t)$.	**Moonlight 式缩放与 WD + 10 步混合 NS**：前 8 步快速逼近，后 2 步修正；RMS 缩放系数采用 **0.18**。	Nesterov，$\mu = 0.95$、WD=0.1。Embedding、LM head、RMSNorm、mHC 的静态 bias/gating factors 用 AdamW。
Kimi K3	$\Delta W_t = -\eta_t s\ \mathrm{NS}(H_t)$。	**Per-Head Muon + QK-Clip**：Q/K/V 按头更新，随后按各头最大 attention logit 裁剪 Q/K 权重。	矩阵参数采用 Muon，WD=0.1。**备注**：K3 原文描述有点少，不确定有没有 RMS 对齐之类的。
MiMo-V2.6-Pro	$R_{t+1} = R_t - 0.1\eta_t\sqrt{\max(m,n)}$ $\cdot\ \mathrm{NS}_{10}(H_{R,t})$, $g_{t+1} = g_t - \eta_t\dfrac{\widehat{m}_{g,t}}{\sqrt{\widehat{v}_{g,t}}+\epsilon}$, $\Delta W_{i,t} = g_{i,t+1}\dfrac{R_{i,t+1}}{\lVert R_{i,t+1}\rVert_2} - W_{i,t}$.	**Muown**：**行方向与行幅度解耦优化**。方向 R 使用 Muon，行幅度 g 使用 Adam，显式控制行范数，缓解权重谱范数漂移。	**预训练**：AdamW。**Mid-training**：隐藏层矩阵切换 Muown；embedding、LM head、router 保留 AdamW。**RL**：LR=3×10^{-6}、WD=0、无 warmup、clip=1.0；Nesterov，$\mu = 0.95$、NS=10、Muon 更新额外 ×0.5；Adam：$\beta_1 = \beta_2 = 0.95$、$\epsilon = 10^{-8}$；router 冻结。
Inkling	$W_{t+1} = (1-\eta_t\lambda_t)W_t + \Delta W_t$。	**Weight decay 与学习率平方耦合调度**。每步实际衰减比例随 η_t^2 调。	**预训练**：大矩阵使用 Muon，其余参数使用 Adam。
MAI-Thinking-1	$\Delta W_t = -\eta_t\dfrac{\widehat{m}_t}{\sqrt{\widehat{v}_t}+\delta}$，逐元素计算。	-	预训练（MAI-Base-1）：$(\beta_1, \beta_2) = (0.95, 0.925)$；WD 一般为 0.1，attention 为 0.01，embedding 为 0.005。RL：$\beta_1 = \beta_2 = 0.95$，**WD=0**。

7. 关键改动的具体公式

7.1 正交化：NS 与改进

我在这里只大概的说一下 NS 的做法，具体推荐非常推荐苏神的 blog（苏神还是太权威了 lol）。原始 Muon、DeepSeek-V4 与 Qwen 的共同计算形式为先归一化动量矩阵，再迭代矩阵多项式。以下用 δ 表示数值稳定常数（不使用时取 0），以区别前文的更新预算 ε：

$$X_0 = \frac{H_t}{\|H_t\|_{\mathrm{F}} + \delta}. \tag{20}$$

$$\boxed{X_{k+1} = a_k X_k + b_k (X_k X_k^\top) X_k + c_k (X_k X_k^\top)^2 X_k.} \tag{21}$$

原始 Muon / Moonlight 使用 5 步固定系数迭代：

$$(a_k, b_k, c_k) = (3.4445, -4.7750, 2.0315). \tag{22}$$

DeepSeek-V4-Pro 前 8 步使用式（22），后 2 步切换为修正系数使奇异值稳定在 1 附近：

$$(a_k, b_k, c_k) = (2, -1.5, 0.5). \tag{23}$$

Qwen3.8-Flash-Next 使用 **8 步 Polar Express [10] 的逐步系数调度**，并在 Frobenius 归一化中取 $\delta = 10^{-14}$。

7.2 按头拆分：

Qwen 的拆分覆盖 QKV、GDN 输入投影以及 SwiGLU 的 gate/up；GLM-5 针对 MLA 的 Q/K/V 上投影，DeepSeek-V4.1 针对 Q/K，K3 则拆分 Q/K/V 的动量矩阵。

K3 还保留了更新后的权重裁剪。 K2 QK-Clip 的通用形式为：当第 h 个头的最大 attention logit $S^h_{\max}$ 超过阈值 τ 时，缩小 Q/K 权重：

$$\begin{aligned} r_h &= \begin{cases} 1, & S^h_{\max} \le \tau, \\ \tau / S^h_{\max}, & S^h_{\max} > \tau, \end{cases} \\ W^h_q &\leftarrow r_h^{\alpha} W^h_q, \qquad W^h_k \leftarrow r_h^{1-\alpha} W^h_k. \end{aligned} \tag{27}$$

其中 α 分配 Q/K 两侧的缩放。MLA 还需区分共享与非共享分量。

7.3 DeepSeek-V4.1：用 Sinkhorn 均衡行列尺度

他真的太爱 Sinkhorn 了... 对 Engram、embedding 或 LM head，设 $W \in \mathbb{R}^{m\times n}$，其中 m 是矩阵行数（对 embedding 和 LM head 即词表大小），n 是 hidden dimension。该组采用以下 Nesterov 动量写法：

$$M_t = 0.95M_{t-1} + 0.05G_t, \qquad H_t = 0.95M_t + 0.05G_t. \tag{28}$$

先将 H_t 中行范数不超过平均行范数 10^{-3} 倍的行置零，得到 $U^{(0)}$；再交替进行行、列归一化：

$$U^{(k)} = \begin{cases} \mathrm{RowL2Norm}_\delta(U^{(k-1)}), & k \text{ 为奇数}, \\ \mathrm{ColL2Norm}_\delta(U^{(k-1)}), & k \text{ 为偶数}, \end{cases} \quad k = 1, \dots, 11. \tag{29}$$

每次除以对应行或列的 ℓ_2 范数加 $\delta = 10^{-20}$。最后一步为行归一化，乘以 $\sqrt{n}$ 后将单位行 ℓ_2 范数转换为单位行 RMS，再用 0.18 对齐更新量级：

$$\boxed{W_{t+1} = W_t - 0.18\eta_t\sqrt{n}\,U^{(11)}.} \tag{30}$$

这一参数组没有 weight decay，Engram 的学习率额外乘以 5。Sinkhorn 通过行列缩放均衡更新幅度，不保证奇异值相等，也不进行 Muon 式正交化。其目标是近似均衡行列 RMS；被置零的行仍保持零。

7.4 MiMo：Muown 单独学习权重行幅度

Muown [11] 是认为 Muon 没有独立控制权重自身的幅度可能会导致权重的行范数持续增长将，因此，它将权重矩阵的每一行表示为行幅度与归一化方向的乘积：

$$W_i = g_i \frac{R_i}{\|R_i\|_2}. \tag{31}$$

其中 g_i 是可学习的行幅度。令 $r_i = \|R_i\|_2$、$d_i = R_i/r_i$，给定权重梯度 G_i，按链式法则分离出幅度梯度 q_i 和方向变量梯度 F_i：

$$q_i = \langle G_i, d_i\rangle, \qquad F_i = \frac{g_i}{r_i}(G_i - q_i d_i). \tag{32}$$

用 Adam 更新 g，用 Muon 更新 R。省略权重衰减项，更新可写为：

$$\begin{aligned} M_t^R &= \mu M_{t-1}^R + F_t, \\ R^+ &= R - \eta_t a_{m,n}\,\mathrm{NS}(F_t + \mu M_t^R), \\ g^+ &= g - \eta_t \frac{\widehat{m}_g}{\sqrt{\widehat{v}_g} + \epsilon}. \end{aligned} \tag{33}$$

其中 $\widehat{m}_g, \widehat{v}_g$ 是 q 的 Adam 矩估计，g 的更新逐元素计算,$a_{m,n} = 0.2\sqrt{\max(m,n)}$。再重构实际权重：

$$\boxed{W_i^+ = g_i^+ \frac{R_i^+}{\|R_i^+\|_2}.} \tag{34}$$

参考资料

[1] 苏剑林：Muon 优化器赏析：从向量到矩阵的本质跨越。

[2] Bernstein & Newhouse：Old Optimizer, New Norm: An Anthology。

[3] Parikh & Boyd：Proximal Algorithms。

[4] Jeremy Bernstein：Deriving Muon。

[5] Keller Jordan：Muon: An optimizer for hidden layers in neural networks。

[6] Yang, Simon & Bernstein：A Spectral Condition for Feature Learning。

[7] 苏剑林：Muon 续集：为什么我们选择尝试 Muon？。

[8] 苏剑林：为什么 Adam 的 Update RMS 是 0.2？。

[9] 苏剑林：QK-Clip：让 Muon 在 Scaleup 之路上更进一步。

[10] Amsel, Persson, Musco & Gower：The Polar Express: Optimal Matrix Sign Methods and Their Application to the Muon Algorithm。

[11] Lion, Hübler, Li, Orvieto & He：Muown: Row-Norm Control for Muon Optimization。

[12] 苏剑林：高阶 MuP：更简明但更高明的谱条件缩放。

[13] 苏剑林：MuP 之上：2. 线性层与最速下降。