

On Policy Distillation Notes

目录

1	符号定义	2
2	从每个 token 的反向 KL 开始	2
3	全词表反向 KL 如何得到最终梯度	3
4	sampled tokens 如何估计全词表梯度	3
5	sampled-token 与全词表 loss 的区别	6
6	未来 Token 的影响与折扣因子	6
6.1	$\gamma = 1$: 完整序列信用分配	8
6.2	$0 < \gamma < 1$: 部分未来信用分配	8
6.3	$\gamma = 0$: 只看即时 token	8
7	OPD 的最终统一公式	8
7.1	Rollout	8
7.2	sampled reverse KL	8
7.3	折扣未来 KL	8
7.4	advantage	9
7.5	importance ratio	9
7.6	Tinker loss	9
7.7	梯度	9

1 符号定义

- $x = (x_1, \dots, x_T)$: 学生生成的完整序列。
- $x_{1..t}$: 生成到第 t 个 token 时的前缀。
- x_{t+1} : 下一 token。
- π_θ : 学生模型。
- π_{teacher} : 固定的教师模型。
- θ : 学生模型参数。
- γ : 未来 KL 的折扣因子。
- β : 代码中的 `kl_penalty_coef`。

此外还涉及两个新符号用于重要性采样:

- q : 真正生成 rollout 的 sampler policy。
- p_θ : 执行训练 forward 时的 learner policy。

理想的严格 on-policy 情况下两者跟 π_θ 应该都相同; 但在实际系统中, rollout 与训练之间通常仍会存在偏差, 例如训推 Infra 等不同, 以及复用同一批 rollout 数据进行多次参数更新时, learner 已逐步偏离生成该数据的 sampler。此外, 现在有不少 infra 会通过重要型采样来传 RL 梯度。

2 从每个 token 的反向 KL 开始

定义固定前缀 $x_{1..t}$ 下, 学生到教师的下一 token 反向 KL:

$$\text{KL}(\pi_\theta \| \pi_{\text{teacher}}) = \mathbb{E}_{x \sim \pi_\theta} [\log \pi_\theta(x_{t+1} | x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1} | x_{1..t})]$$

更严格地展开为全词表求和:

$$D_t(x_{1..t}) = \sum_{x_{t+1}} \pi_\theta(x_{t+1} | x_{1..t}) \cdot [\log \pi_\theta(x_{t+1} | x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1} | x_{1..t})].$$

它比较的是:

$$\pi_\theta(\cdot | x_{1..t}) \quad \text{与} \quad \pi_{\text{teacher}}(\cdot | x_{1..t}),$$

即同一个学生访问到的前缀下, 两个下一 token 条件分布的反向 KL。

为简化记号, 定义单 token 的采样 KL:

$$d_t = \log \pi_\theta(x_{t+1}|x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1}|x_{1..t}).$$

3 全词表反向 KL 如何得到最终梯度

固定 $x_{1..t}$, 对 D_t 求梯度:

$$\begin{aligned} \nabla_\theta D_t &= \sum_{x_{t+1}} \nabla_\theta \pi_\theta(x_{t+1}|x_{1..t}) d_t \\ &\quad + \sum_{x_{t+1}} \pi_\theta(x_{t+1}|x_{1..t}) \nabla_\theta \log \pi_\theta(x_{t+1}|x_{1..t}). \end{aligned}$$

使用对数求导:

$$\nabla_\theta \pi_\theta = \pi_\theta \nabla_\theta \log \pi_\theta,$$

得到:

$$\nabla_\theta D_t = \mathbb{E}_{x_{t+1} \sim \pi_\theta} [(d_t + 1) \nabla_\theta \log \pi_\theta(x_{t+1}|x_{1..t})].$$

其中:

$$\begin{aligned} \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta] &= \sum_{x_{t+1}} \pi_\theta(x_{t+1}|x_{1..t}) \nabla_\theta \log \pi_\theta(x_{t+1}|x_{1..t}) \\ &= \sum_{x_{t+1}} \nabla_\theta \pi_\theta(x_{t+1}|x_{1..t}) \\ &= \nabla_\theta 1 \\ &= 0. \end{aligned}$$

所以 +1 在期望中消失:

$$\boxed{\nabla_\theta D_t = \mathbb{E}_{x_{t+1} \sim \pi_\theta} [d_t \nabla_\theta \log \pi_\theta(x_{t+1}|x_{1..t})]}$$

也就是:

$$\boxed{\nabla_\theta D_t = \mathbb{E}_{x_{t+1} \sim \pi_\theta} [(\log \pi_\theta(x_{t+1}|x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1}|x_{1..t})) \nabla_\theta \log \pi_\theta(x_{t+1}|x_{1..t})]}.$$

这就是 OPD 最核心的 token-level policy-gradient 形式。

4 sampled tokens 如何估计全词表梯度

由于直接使用全词表做反向 KL 太贵了, 目前也只有 DeepSeek v4 使用,

大家一般会使用 sampled tokens 或者 topk 进行估计。下面先证明 K 个 sampled tokens 的 Monte Carlo 平均是无偏的，然后再看现在实践中常用的 $K = 1$ 特例。

第三节最后得到的是：

$$\nabla_{\theta} D_t = \mathbb{E}_{x_{t+1} \sim \pi_{\theta}} [d_t \nabla_{\theta} \log \pi_{\theta}(x_{t+1} | x_{1..t})].$$

把这个期望重新展开成全词表求和：

$$\begin{aligned} \nabla_{\theta} D_t &= \sum_{x_{t+1}} \pi_{\theta}(x_{t+1} | x_{1..t}) \\ &\quad \cdot [(\log \pi_{\theta}(x_{t+1} | x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1} | x_{1..t})) \nabla_{\theta} \log \pi_{\theta}(x_{t+1} | x_{1..t})]. \end{aligned}$$

也就是说，真实梯度需要枚举每个可能的下一 token，并用学生概率

$$\pi_{\theta}(x_{t+1} | x_{1..t})$$

作为权重加权求和。

如果不枚举全词表，而是从学生分布中采样 K 个 token：

$$x_{t+1}^{(1)}, \dots, x_{t+1}^{(K)} \sim \pi_{\theta}(\cdot | x_{1..t}),$$

其中第 k 个样本对应：

$$d_t^{(k)} = \log \pi_{\theta}(x_{t+1}^{(k)} | x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1}^{(k)} | x_{1..t}).$$

对第 k 个 sampled token，可以构造一个单样本梯度估计：

$$\hat{g}^{(k)} = d_t^{(k)} \nabla_{\theta} \log \pi_{\theta}(x_{t+1}^{(k)} | x_{1..t}).$$

然后对 K 个样本取平均：

$$\hat{g}_K = \frac{1}{K} \sum_{k=1}^K \hat{g}^{(k)} = \frac{1}{K} \sum_{k=1}^K d_t^{(k)} \nabla_{\theta} \log \pi_{\theta}(x_{t+1}^{(k)} | x_{1..t}).$$

先看单个 $\hat{g}^{(k)}$ 的期望。因为每个 $x_{t+1}^{(k)}$ 都来自

$$\pi_{\theta}(\cdot | x_{1..t}),$$

所以：

$$\begin{aligned}
\mathbb{E}[\hat{g}^{(k)}] &= \sum_{x_{t+1}^{(k)}} \pi_{\theta}(x_{t+1}^{(k)} | x_{1..t}) \\
&\quad \cdot \left[\left(\log \pi_{\theta}(x_{t+1}^{(k)} | x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1}^{(k)} | x_{1..t}) \right) \nabla_{\theta} \log \pi_{\theta}(x_{t+1}^{(k)} | x_{1..t}) \right] \\
&= \nabla_{\theta} D_t.
\end{aligned}$$

因此 K 个样本平均后的期望为：

$$\begin{aligned}
\mathbb{E}[\hat{g}_K] &= \frac{1}{K} \sum_{k=1}^K \mathbb{E} \left[d_t^{(k)} \nabla_{\theta} \log \pi_{\theta}(x_{t+1}^{(k)} | x_{1..t}) \right] \\
&= \frac{1}{K} \sum_{k=1}^K \nabla_{\theta} D_t \\
&= \nabla_{\theta} D_t.
\end{aligned}$$

所以 K 个 sampled tokens 的平均是全词表梯度的无偏 Monte Carlo 估计。

现在实践里常取 $K = 1$ 。此时估计量退化为：

$$\boxed{\hat{g}_1 = d_t \nabla_{\theta} \log \pi_{\theta}(x_{t+1} | x_{1..t}), \quad x_{t+1} \sim \pi_{\theta}.}$$

它仍然无偏，但因为只用一个 sampled token，方差比更大的 K 更高。

我们的上述推导在工程实现上还漏掉了一个很重要的事情：sampled-token estimator 不能直接把 sampled KL 当作普通 loss 反传，而需要 stop-gradient。

实际上我在一开始推导的时候也完全忘掉了，是看到了官方代码才发现有些不对劲儿（采样之后，

$$x_{t+1} \sim \pi_{\theta},$$

这个 x_{t+1} 在自动微分看来只是一个固定 token；采样概率本身没有显式留在计算图里。因此工程实现要复现的不是 $\nabla_{\theta} d_t$ ，而是上一节推导出的 score-function 梯度估计器：

$$\hat{g}_K = \frac{1}{K} \sum_{k=1}^K d_t^{(k)} \nabla_{\theta} \log \pi_{\theta}(x_{t+1}^{(k)} | x_{1..t}).$$

实现这个估计器的代理损失应写成：

$$\boxed{\mathcal{L}_{\text{MC}} = \frac{1}{K} \sum_{k=1}^K \text{sg} \left[d_t^{(k)} \right] \log \pi_{\theta}(x_{t+1}^{(k)} | x_{1..t})}$$

其中 sg 表示 stop-gradient。它只把 $d_t^{(k)}$ 当成数值权重，让自动微分只穿过后面的 score function：

$$\nabla_{\theta} \mathcal{L}_{\text{MC}} = \frac{1}{K} \sum_{k=1}^K \text{sg} \left[d_t^{(k)} \right] \nabla_{\theta} \log \pi_{\theta}(x_{t+1}^{(k)} | x_{1..t}).$$

如果不加 stop-gradient, 写成 $d_t \log \pi_{\theta}(x_{t+1} | x_{1..t})$, 自动微分会多出:

$$\log \pi_{\theta}(x_{t+1} | x_{1..t}) \nabla_{\theta} d_t,$$

这里和全词表 KL 的区别是: 全词表方法没有离散采样, 完整目标

$$\mathcal{L}_t^{\text{full}} = \sum_{x_{t+1}} \pi_{\theta}(x_{t+1} | x_{1..t}) [\log \pi_{\theta}(x_{t+1} | x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1} | x_{1..t})]$$

已经把每个 token 的概率权重 $\pi_{\theta}(x_{t+1} | x_{1..t})$ 显式写在求和里, 所以可以直接自动微分整个真实目标, 不需要 stop-gradient。

5 sampled-token 与全词表 loss 的区别

这两个方法估计的是同一个固定前缀条件 KL, 但实现方式不同。

方面	全词表 loss	sampled-token loss
下一 token	枚举所有词表 token	只使用实际采样 token
目标	精确计算条件 KL	Monte Carlo 估计条件 KL 梯度
教师输出	完整词表概率或 logits	被采样 token 的 logprob
方差	对当前前缀无采样方差	$K = 1$ 时方差较大
计算量	与词表大小相关	每个位置只需 sampled token 的教师 logprob
自动微分	直接对完整 KL 目标反传	使用 policy-gradient surrogate
stop-grad	不需要特殊 stop-grad	d_t 作为 advantage 时需要 stop-grad

6 未来 Token 的影响与折扣因子

到这里为止, 我们一直在固定前缀 $x_{1..t}$ 下分析下一 token 的条件 KL。但实际上, 我们会碰到一个很常见的问题:

当前 token 改变后, 后面会访问到的前缀也会改变; 这些未来位置上的 KL 要不要归因给当前 token?

如果把整条 rollout 都看作学生模型生成的样本, 一个自然的序列级目标是沿轨迹累加每个位置的 KL:

$$\mathcal{J}(\theta) = \mathbb{E}_{x \sim \pi_\theta} \left[\sum_{t=0}^{T-1} d_t \right],$$

其中：

$$d_t = \log \pi_\theta(x_{t+1}|x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1}|x_{1..t}).$$

这个目标也可以理解为完整序列分布上的反向 KL，因为：

$$\log \pi_\theta(x) = \sum_t \log \pi_\theta(x_{t+1}|x_{1..t}),$$

教师同理。

对 $\mathcal{J}$ 求梯度：

$$\begin{aligned} \nabla_\theta \mathcal{J} = \mathbb{E}_{x \sim \pi_\theta} \left[\left(\sum_t \nabla_\theta \log \pi_\theta(x_{t+1}|x_{1..t}) \right) \left(\sum_k d_k \right) \right. \\ \left. + \sum_k \nabla_\theta \log \pi_\theta(x_{k+1}|x_{1..k}) \right]. \end{aligned}$$

最后一项的期望为零。再利用因果性，第 t 个 token 的 score 不需要乘过去的 d_k , $k < t$ ，得到：

$$\nabla_\theta \mathcal{J} = \mathbb{E}_{x \sim \pi_\theta} \left[\sum_{t=0}^{T-1} \left(\sum_{k=t}^{T-1} d_k \right) \nabla_\theta \log \pi_\theta(x_{t+1}|x_{1..t}) \right].$$

因此，严格的序列级反向 KL 梯度中，第 t 个 token 的权重应该是：

$$d_t + d_{t+1} + \cdots + d_{T-1}.$$

原因是当前 token 不仅影响当前 KL，还会改变后面访问到的所有前缀。

因此我们定义折扣未来 KL：

$$G_t^{(\gamma)} = \sum_{k=t}^{T-1} \gamma^{k-t} d_k.$$

即：

$$G_t^{(\gamma)} = d_t + \gamma d_{t+1} + \gamma^2 d_{t+2} + \cdots.$$

对应的 KL advantage 为：

$$A_t^{(\gamma)} = -\beta G_t^{(\gamma)}.$$

不同 γ 的含义如下。

6.1 $\gamma = 1$: 完整序列信用分配

$$G_t^{(1)} = d_t + d_{t+1} + \cdots + d_{T-1}.$$

这对应序列级目标下的无折扣信用分配。

6.2 $0 < \gamma < 1$: 部分未来信用分配

$$G_t^{(\gamma)} = d_t + \gamma d_{t+1} + \gamma^2 d_{t+2} + \cdots.$$

保留未来影响，但越远的 KL 权重越小。

6.3 $\gamma = 0$: 只看即时 token

$$G_t^{(0)} = d_t.$$

当前 token 只根据当前位置的教师信号更新，不承担未来 KL。这也是目前的默认选择。主要是因为 TML 官方博客里有提及：正折扣因子在数学上更完整，但实验中没有观察到性能改善，因此为了简单，主动使用零折扣。

7 OPD 的最终统一公式

7.1 Rollout

$$x_{t+1} \sim q(\cdot | x_{1..t}).$$

7.2 sampled reverse KL

$$d_t = \log q(x_{t+1} | x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1} | x_{1..t}).$$

7.3 折扣未来 KL

$$G_t^{(\gamma)} = \sum_{k=t}^{T-1} \gamma^{k-t} d_k.$$

7.4 advantage

$$A_t = -\beta \text{stopgrad} \left[G_t^{(\gamma)} \right].$$

7.5 importance ratio

$$\rho_t(\theta) = \frac{p_\theta(x_{t+1}|x_{1..t})}{q(x_{t+1}|x_{1..t})}.$$

7.6 Tinker loss

$$\mathcal{L}_{\text{OPD}} = -\sum_t \rho_t(\theta) A_t.$$

7.7 梯度

$$\nabla_\theta \mathcal{L}_{\text{OPD}} = \beta \sum_t \rho_t(\theta) G_t^{(\gamma)} \nabla_\theta \log p_\theta(x_{t+1}|x_{1..t}).$$

默认：

$$\gamma = 0,$$

所以：

$$G_t^{(0)} = d_t,$$

最终为：

$$\nabla_\theta \mathcal{L}_{\text{OPD}} = \beta \sum_t \frac{p_\theta(x_{t+1}|x_{1..t})}{q(x_{t+1}|x_{1..t})} [\log q(x_{t+1}|x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1}|x_{1..t})] \nabla_\theta \log p_\theta(x_{t+1}|x_{1..t}).$$

严格 on-policy 时：

$$p_\theta = q = \pi_\theta,$$

化简为：

$$\nabla_\theta \mathcal{L}_{\text{OPD}} = \beta \sum_t [\log \pi_\theta(x_{t+1}|x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1}|x_{1..t})] \nabla_\theta \log \pi_\theta(x_{t+1}|x_{1..t}).$$