视觉编码器架构与多模态训练对比

压缩口径：总倍率按时间 × 高 × 宽 排列，计算模型入口像素/时间网格到输出视觉 token 网格的名义倍率，包含 patchify；N 默认指 patchify 后、末端合并前的有效 token 数。抽帧、resize 不计入网络压缩；边界 padding 按取整处理。静态图像复制时间维不算真实帧压缩；图像倍率中的时间 1 仅作占位。

动态分辨率口径：可变二维 patch 网格和有效 token 数，允许预算内 resize/pad。

模型	视觉模块架构	时空压缩、位置编码与动态分辨率	多模态训练 Recipe	视觉输入 infra 优化
MAI-Base-2	最大最新最强的 **Encoder-Free!!!**	——	——	——
Kimi K3	**MoonViT-V2，401M，27 层、宽度 1024**。 **Attention：MHA，Q/K/V = 12/12/12 头，每头 128 维**；按官方公开代码，每个 chunk 内全部 THW token 做非因果全局 attention（时空联合）。 FFN：普通两层 **GELU-tanh MLP，1024→4096→1024**；编码器末端 RMSNorm。 Projector：合并后 **4096→4096→7168，GELU，末端 RMSNorm**。	**总倍率：$t \times 28 \times 28$；满 4 帧 chunk 为 $4 \times 28 \times 28$。** **Patch / 压缩**：Conv2d，$1 \times 14 \times 14$；27 层 ViT + 末端 RMSNorm 后，对同空间位置、同通道的 t 帧特征做 `mean(dim=0)`，再将空间 2×2 拼到通道维，$N \to N/(4t)$。每 chunk $1 \le t \le 4$；一次 forward 可打包多个 chunk，各自池化；独立图片按 $t = 1$ 处理。 **位置**：64×64 可学习空间表双线性插值 + 固定时间编码；attention 内 2D RoPE，空间坐标跨帧重复。 **动态分辨率：是**。可变 T, H, W 网格、变长 patch 打包，`cu_seqlens` 隔离 chunk。最高 3584×3584。	**MoonViT-V2 从零训练，从主模型训练开始即联合图文训练，采用自回归目标。** 视觉数据包括 caption、交错图文、OCR、感知、视频、视觉代码，以及 SVG、网页、游戏、CAD 等渲染数据。优化使用 per-head Muon，**1% warmup、cosine 调度、weight decay 0.1**。 相关后训练为 **SFT → 含视觉任务的领域专家 RL → 多教师 on-policy distillation**。	视觉 Context Parallelism 按图像 patch 分片、gather KV，并动态划分子组以平衡大图负载；将视觉编码器前向、反向安排进主训练流水线的空闲区间，减少视觉部分造成的等待。
Qwen3.8-Flash-Next	**ViT，415.9M，27 层、宽度 1152**。 **Attention：MHA，Q/K/V = 16/16/16 头，每头 72 维**；每个时间片内做非因果全局 attention。 FFN：普通两层 **GELU-tanh MLP，1152→4304→1152**。 Projector：LayerNorm 后空间 2×2 拼接，**4608→4608→2560，GELU**。	**总倍率：$2 \times 32 \times 32$；时间在 patchify 压缩 2 倍，之后不再压缩。** **Patch / 压缩**：Conv3d kernel=stride=$2 \times 16 \times 16$；末端 LayerNorm 后空间 2×2 拼接 + MLP，$N \to N/4$，仅额外压缩空间，无末端时间池化。 **位置**：48×48 绝对位置表双线性插值；视觉 attention 内 2D RoPE。 **动态分辨率：是**。可变 T, H, W 网格、变长 patch 打包，`cu_seqlens` 隔离 chunk。	——	——
DeepSeek-V4.1-Flash	**DeepSeek-ViT，411.8M，32 层、宽度 1024**。 **Attention：MHA，Q/K/V = 16/16/16 头，每头 64 维**；每张图像内做非因果全局 attention。 FFN：**SwiGLU，1024→2816→1024**；三个投影；Pre-RMSNorm 与编码器末端 RMSNorm。 Projector：空间展开后 **9216→5120→5120，GELU**；独立 aligner **73.4M**。	**总倍率：$1 \times 42 \times 42$。** **Patch / 压缩**：$1 \times 14 \times 14$ RGB patch 展平 + Linear，588→1024；末端 `unfold(kernel=stride=3)` 做3×3 **pixel-unshuffle，**$N \to N/9$。不足 3 的倍数时 padding，输出空间网格为 $\lceil h/3 \rceil \times \lceil w/3 \rceil$，按取整计算；图像前向无时间池化。 **位置**：无绝对位置表；视觉 2D RoPE，θ=10000。 **动态分辨率：是**。按宽高和总 token 预算规划网格，通常等比 resize/pad、14 像素对齐；默认 1024 token 含分隔符。超宽图触发 `vision_max_wh_ratio` 时直接 resize。	从零训练 **DeepSeek-ViT**。 ① **SigLIP 的 sigmoid 对比损失：47B 图文对**，alt-text，最高 224^2 像素。 ② 接入 **4B 辅助 LLM**，以 caption、alt-text、图表、OCR 做 **236B token 的 NTP**，分辨率 544^2-1344^2；随后丢弃辅助 LLM。 ③ 主模型在 **45T 全模态 token** 上训练：先冻结视觉塔，仅末端 Norm、projector 可训；进入 LR 衰减阶段再以更小 LR 解冻视觉塔。主训练 LR 为 2.6×10^{-4}，28T-40T 间衰减到 2.6×10^{-5}。 ④ **SFT→RL→OPD**，包含多模态任务。	对比阶段将特征 All-Gather 与计算重叠；视觉编码与主模型训练分阶段调度，并平衡图像分配、避免重复加载。多模态 RL 中增量传输图像，缓存 CPU 解码/预处理结果，供 rollout 与训练复用。
Muse Spark Open	**Perception Encoder，1.8B，50 层、宽度 1536**。 **Attention：MHA，Q/K/V = 16/16/16 头，每头 96 维**；非因果 **32×32 patch** 局部窗口；第 **4、8、…、48、50** 层为全局 attention。 FFN：普通两层 **GELU MLP，1536→8960→1536**；Pre-LayerNorm，编码器入口和末端 LayerNorm。 Projector：合并后 **6144→4096→4096→8192**，前两层后接 GELU，末端无缩放 RMSNorm。	**总倍率：视频 $2 \times 28 \times 28$；静态图像 $1 \times 28 \times 28$。** **Patch / 压缩**：$2 \times 14 \times 14$ RGB 像素块展平 + Linear，**1176→1536**；末端 LayerNorm 后空间 2×2 pixel-unshuffle，**1536→6144，**$N \to N/4$。时间在入口融合 2 帧；静态图像复制时间维。 **位置**：32×32 可学习空间表双线性插值 + 视觉 2D axial RoPE，θ=10000。 **动态分辨率：是**。按宽高比和 token 预算 resize、28 像素对齐；变长 patch 打包，`cu_seqlens` 隔离图像/时间片，局部层另按窗口分段。	——	——

续下页

模型	视觉模块架构	时空压缩、位置编码与动态分辨率	多模态训练 Recipe	视觉输入 infra 优化
MiMo-V2.6-Pro	**MiMo-ViT，681M，28 层、宽度 1280**。 **Attention：GQA，Q/K/V = 32/8/8 头，每头 64 维**；24 个局部层为带 sink 的双向 SWA，一维序列左右各 64 个位置，按行/列序列化分组切换；全局层为 **[0,9,18,27]，0 基编号**。 FFN：**SwiGLU，1280→4608→1280**；块内 RMSNorm。 Projector：LayerNorm 后空间 2×2 拼接，**5120→5120→6144，GELU**；独立 merger。	**总倍率：按模型入口时间轴为 $2 \times 32 \times 32$；末端时间倍率为 1**。 **Patch / 压缩**：Conv3d 等价投影，kernel=stride=$2 \times 16 \times 16$，可展开权重用 Linear 计算；末端 LayerNorm + 空间 2×2 拼接 + MLP，$N \to N/4$，无额外时间池化。`temporal_compression_ratio=1` 不应另乘一次时间倍率；入口时间块跨度由 `temporal_patch_size=2` 给出。 **位置**：无绝对位置表；视觉 2D axial RoPE。 **动态分辨率：是**。可变网格 + `cu_seqlens` 分隔图/时间片，局部层按行列重排。有像素预算。	① 视觉独立预训练：ViT 从零初始化，接入小型预训练 LLM；辅助 LLM 保持可训练，仅使用多模态理解交叉熵/NTP。训练超过 **4T 图像 token**。 ② Pro 主模型先做 **27T 文本 token** 训练，再接入自研预训练 ViT，联合训练 **3T 全模态 token**；总计 30T。预训练用 AdamW。 ③ 含视觉轨迹的 mid-training：256K→1M，并切换矩阵优化器为 Muown。 ④ 短 SFT→ 包含视觉任务的混合任务 RL，得到 **Pro-RL**；再经 MOPD2 得到 **Pro-MOPD**。	视觉编码器在 TP 组内复制，先按图像做数据并行负载均衡，再把 embedding 重分发到对应 token 所在 rank；像素留在分布式 KV 存储，仅在编码时获取。多轮任务只传新增的多模态 payload。
Thinking Machines Inkling	**HMLP，83.74M，4 级局部折叠与线性投影，输出宽度 6144**。 局部投影：HMLP 前三级为 **75→128、512→320、5120→4800**，各级使用 **Linear→RMSNorm→GELU**。 Projector：HMLP 最后一级为 **9600→6144，末端 RMSNorm**。	**总倍率：视频 $2 \times 40 \times 40$；静态图像 $1 \times 40 \times 40$**。 **Patch / 压缩**：HMLP 前三级依次将空间 5×5、2×2、4×4 邻域拼到通道维，每级再接线性投影，空间网格 $40 \times 40 \to 8 \times 8 \to 4 \times 4 \to 1 \times 1$；第四级拼接两个时间位置，投影为 6144 维的 1 个 token。静态图像复制时间维，不计真实帧压缩。 **位置**：HMLP 内无绝对位置表/RoPE、无 patch 间 attention。 **动态分辨率：是**。按输入宽高切 40×40 块，边缘 padding；可选等比 Lanczos 重缩放，官方建议每边 40-4096 像素。	——	——
GLM-5.3-Flash	**ViT，404.2M，24 层、宽度 1024**。 **Attention：MHA，Q/K/V = 16/16/16 头，每头 64 维**；空间网格内做非因果全局 attention；逐头 **QK RMSNorm**。 FFN：**SwiGLU，1024→4096→1024**，带 bias；**gate 仅上界裁剪至 10，up 裁剪至 [-10,10]**；Pre-RMSNorm 与编码器末端 RMSNorm，$\epsilon = 10^{-5}$。 Projector：空间卷积后 **4096→4096，LayerNorm+GELU，再接中间维 10240 的 clipped SwiGLU→4096**；独立 Projector 与末端空间卷积合计 **159.4M**。	**总倍率：按模型入口时间轴为 $2 \times 28 \times 28$；patchify 后时间倍率为 1**。 **Patch / 压缩**：Conv3d kernel=stride=$2 \times 14 \times 14$；末端 **Conv2d，1024→4096，kernel=stride=2**，将高宽各减半，$N \to N/4$；无额外时间池化。空间压缩使用有学习参数的卷积。 **位置**：无绝对位置表；视觉 2D axial RoPE。 **动态分辨率：是**。`smart_resize` 按预算选画布，等比 bicubic resize + 右/下 padding，28 像素对齐；变长 patch + `cu_seqlens` 隔离图/时间片。静态图像在入口复制时间维；部署端可覆盖预算。	——	——
dots3-note-prev	**MoE ViT，7B 总参数、1.2B 激活参数，42 层、宽度 1536**。发布实现估算 **6.80B / 单 token 激活 1.216B**。 **Attention：MHA，Q/K/V = 24/24/24 头，每头 64 维**；每帧内做非因果全局 attention；**QK RMSNorm**。 FFN：前 **25 层 dense SwiGLU，1536→4224→1536**；后 **17 层视觉 MoE**，专家数依次 **4,8,⋯,64,64**，**Top-2**，每专家 **1536→2112→1536 SwiGLU**；Pre-RMSNorm 与编码器末端 RMSNorm。 Projector：LayerNorm 后空间 2×2 拼接，**6144→6144→5120，GELU**；独立 adapter 另 **69.2M**。	**总倍率：$1 \times 28 \times 28$；时间不压缩**。 **Patch / 压缩**：Conv2d，$1 \times 14 \times 14$；前置 `pre_pixel_shuffle` 仅作 2×2 block-major 重排，token 数不变。42 层之后 adapter 才做空间 2×2 拼接，$N \to N/4$；图像/视频逐帧编码，无时间池化。 **位置**：无可学习绝对位置表；视觉 2D axial RoPE，空间坐标逐帧重复。 **动态分辨率：是**。可变 `grid_thw`、变长 patch 和 `cu_seqlens` 分隔图/时间片。	——	——

SigLIP 2

要说近两年影响力最大的 vision encoder，当之无愧是 SigLIP 2，SigLIP 2 充分展现了视觉学习的现代经典思路：究极缝合怪，集百家之长。（关于这点可以稍稍参考我之前的 blog "从 VAE 到 RAE：既要又要的生成 latent 表征"）

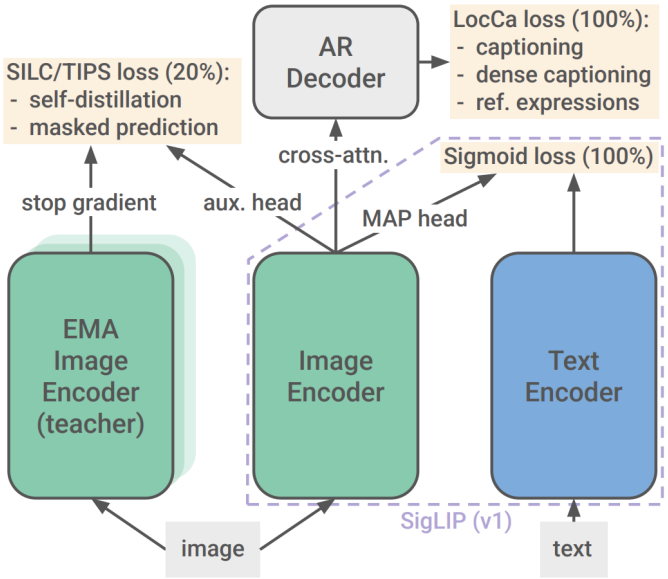
下面我们以用的最多的 So400m 版本聊一聊

1. 架构

- 标准 ViT，视觉塔约 400M，27 层、Hidden 1152。
- Attention：MHA，Q/K/V = 16/16/16 Heads，Head Dim 72；非因果全局 Attention。
- FFN：GELU，1152→4304→1152；LayerNorm，Multihead Attention Pooling（用一个 Learnable Query 在最后一层对所有 Patch 做 Cross-Attention，代替 Mean Pooling 或 CLS Token）。
- Text Encoder：同样 27 层、Hidden 1152；文本长度 64，Gemma 256K Tokenizer。
- 训练期使用 LocCa Decoder、EMA Teacher 和辅助 Head，最终全部丢弃。

2. Patch / 分辨率 / 位置编码

- Patch：初始预训练使用 16×16，256² 图像，256 Visual Tokens；不压缩 Patch Tokens。
- 固定分辨率：Patch14 支持 224²、384²；Patch16 支持 256²、384²、512²。
- 位置编码：Learned Absolute Position Embedding，不使用 RoPE。
- 动态分辨率：NaFlex，尽量保持原始宽高比；通过双线性插值适配位置编码，支持 128/256/576/784/1024 Token Budget。



3. 训练方法

下面简单聊聊 SigLIP2 千奇百怪的 loss 们：

① SigLIP + LocCa（全程训练，Loss 1:1）

- Sigmoid Loss：Batch 内所有图文 Pair 独立进行二分类，匹配为正样本，其余为负样本。

- LocCa：在 ViT 的 Patch Features 上增加 Cross-Attention Decoder，执行三个生成任务：
  - Image → Caption：生成整图描述。
  - Region Caption → BBox：根据区域描述预测坐标。
  - BBox → Region Caption：根据坐标生成区域描述。
- 训练数据：从 Alt-Text 提取词组，用 Open-Vocabulary Detector 自动生成 Region-BBox 伪标签。
- 训练方式：每张图像共享一次 ViT Forward，额外执行 3 次 Decoder Forward；Captioning 有 50% 概率使用非因果并行 Token Prediction。
- Decoder 仅用于训练，推理时丢弃。

② SILC / TIPS（最后 20% 加入）

采用 DINO/iBOT 风格的 EMA Teacher-Student 自监督：

- SILC（Loss 权重 1.0）：Teacher 看 1 个 Global View，Student 看 8 个 Local Views，通过额外 MLP Head 匹配全局语义分布，增强局部与全局表征一致性。
- TIPS（Loss 权重 0.25）：Teacher 看完整 Global View，Student 随机 Mask 50% Patch Embeddings，预测对应位置的 Teacher Features，不是重建 RGB。
- Teacher 由 Student 的 EMA 更新，不反传梯度；SigLIP/LocCa 仍使用原始图像，自监督额外使用增强图像。

So400m 最后 20% 的总 Loss：

$$\mathcal{L} = \mathcal{L}_{\text{SigLIP}} + \mathcal{L}_{\text{LocCa}} + \mathcal{L}_{\text{SILC}} + 0.25\mathcal{L}_{\text{TIPS}}$$

③ 分辨率适配（两条独立分支）

FixRes：从 95% 训练进度的 Checkpoint 分叉。

- 提高图像分辨率，对 Learned Position Embedding 进行 2D 插值，例如 16×16 → 24×24。
- Patch16 → Patch14 时，通过 PI-Resize（Pseudoinverse）转换 Patch Embedding 权重，尽量保持投影结果一致。
- 在目标分辨率继续剩余 5% 训练，保留全部 Loss；不同分辨率分别保存 Checkpoint。

NaFlex：从 90% Checkpoint 分叉。

- 尽量保持原始宽高比，Resize 至 Patch Size 整数倍，不强制正方形。
- 每个 Batch 从 `{128, 256, 576, 784, 1024}` 采样 Token Budget。
- 对 16×16 Learned PE 双线性插值到目标 Patch Grid，Attention Mask 屏蔽 Padding。
- 训练末段 LR Schedule 延长 3.75 倍；不使用 SILC/TIPS，仅保留 SigLIP + LocCa。

④ ACID：小模型的数据筛选蒸馏

So400m 后面可以作为 ViT-B 的 Teacher 进行 ACID 蒸馏

- So400m 先在高质量数据上额外训练 1B 样本。
- Teacher 与 Student 为候选样本计算 Learnability，优先选择 Teacher 已掌握、Student 尚未掌握的样本。
- 从 64K Super-batch 筛选 32K，Student 继续训练 4B 样本。
- 只使用 Sigmoid Loss，不直接蒸馏 Teacher Logits / Features。

Perception Encoder（PE-G）

不同于 SigLIP 2 组合多种预训练 Loss，Perception Encoder（PE）主要依靠大规模 CLIP Contrastive Learning，发现强大的通用视觉特征隐藏在中间层，再通过 Alignment Tuning 将这些能力迁移到输出层。

1. 架构

- 标准 ViT，视觉塔 1.88B，50 层、Hidden 1536。
- Attention：MHA，Q/K/V = 16/16/16 Heads，Head Dim 96；非因果全局 Attention。
- FFN：1536→8960→1536；8 Heads Attention Pooling，不使用 CLS Token。
- Text Encoder：0.47B，24 层、Hidden 1280；20 Heads，FFN 5120，文本长度 72；图文对比维度 1280。

2. Patch / 分辨率 / 位置编码

- Patch：14×14，最终 448^2 图像对应 1024 Visual Tokens，不压缩 Patch Features。
- 位置编码：2D RoPE + Learned Absolute PE，后者支持插值。
- Progressive Resolution：98^2→154^2→224^2→336^2→448^2。

3. 训练方法

① CLIP Contrastive Pretraining

- Loss：传统 CLIP 双向 Softmax Contrastive Loss，而非 SigLIP 的 Sigmoid Loss。
- 数据：MetaCLIP 筛选的 5.4B Image-Text Pairs，累计 86B Samples Seen。
- 优化：LAMB，Batch Size 131K，LR 2e-3，训练 656K Steps。
- Augmentation：Random Crop（0.08-1.0）、Color Jitter、Horizontal Flip。
- Mask Regularization：额外复制 1/16 Batch，随机 Mask 40% Patches，对齐 Masked/Unmasked Features 的 Cosine Similarity；与 CLIP Loss 的梯度路径分离。

② Video Finetuning

- 先使用 50M Images 做 Cooldown，再使用 22M Recaptioned Videos 微调。
- 视频 Caption：结合 Video Captioner、Frame Captions 和 Metadata，再由 Llama 3.3 70B 整合。
- 每个视频均匀采样 8 Frames，分别经过相同 ViT，Mean Pooling 得到 Video Embedding。
- 继续使用 CLIP Contrastive Loss，不增加 Temporal Attention。

③ Intermediate Layer：

PE-G 的最佳视觉特征不一定在最后一层：

- OCR：第 38 层；VQA：第 47 层。
- Detection / Depth：第 39 层；Tracking：第 32 层。
- 从第 33 层开始出现 Global Tokens，后面 18 层逐渐承担全局语义聚合，导致部分局部空间信息丢失。

因此，作者从 PE-core-G 分叉出两种 Alignment：

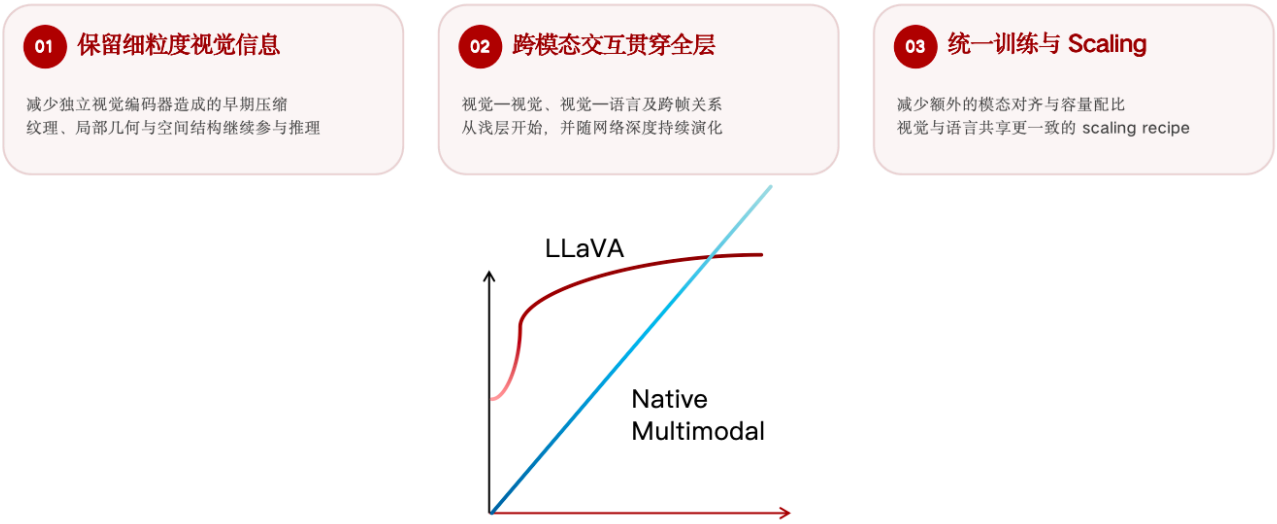
- PE-lang-G：保留前 47 层，丢弃最后 3 层；连接 Llama 3.2 3B + MLP Projector，使用 70M 多模态样本通过 CE Loss 联合微调，增强 OCR/VQA 等语言理解能力。
- PE-spatial-G：同时蒸馏 Frozen PE-core-G 第 41 层的语义特征与 SAM 2.1 的 Mask Logits 空间对应关系；使用 75% Masking，训练 300M Samples，使最后一层具备更强的 Dense Features。

Encoder-Free

最后顺便推销在我们力推的 Encoder-Free 吧！非常令人振奋的是，在我写这篇 blog 的时候，微软发布了他们最新的 3T 模型 MAI-Base-2，正是 Encoder Free VLM！

Encoder Free 的核心就是去掉独立的深层视觉编码器，改用轻量的 patchify 投影输入，可以参考 NEO NEO-ov , SenseNova-U1 , SenseNova-U1.5 , Gemma4-12B , Inking（建议考古 Haiwen Diao 的 publication list，原生建模的老大哥）

这会有什么好处呢？



此外，我之前也有篇 Blog " 为什么我们想拿掉 Vision Encoder？"(可以在主页搜 hh) 也有提及 Infra 的一些小小小小小好处。归根结底，我一向的 taste 是"removing inductive bias as much as possible to let the model architecture take its natural and intended form"，如果去除它也可以，那 Why not?